

PhiloVista-1620：DeepSeek Flash 高强度思考·新版标准答案评测报告

生成时间：2026-10-04 07:47 UTC
API 响应时间：2026-09-29T18:00:43.067433+00:00 至 2026-09-29T19:03:28.001860+00:00
模型：deepseek-flash；thinking.type=enabled；reasoning_effort=high。

本次重新评分

标准答案改用用户提供的
D:\Project\PhiloVista-1800-A-Multi-source-Benchmark\PhiloVista-1620_labels.csv，SHA-256 为 6d1f361cd2a813f3fd6e86f2383e82511cd0190dc98fef14c44a12c82038eb3f。沿用已保存的高强度思考原始回答，没有重新调用模型；图片、prompt 和概念表的哈希均由评分脚本逐项核对。与上次报告所用标签相比，1570 / 1,620 张图片的三标签集合发生变化。本报告下方的全部准确率和逐例标准答案均按新版 CSV 计算。

准确率：仅以有效输出为分母

Prompt	有效输出 / 1,620	有效输出覆盖率	命中标签 / 有效标签	Hits@3 准确率	三标签完全匹配 / 有效输出	完全匹配率
中文	1620 / 1620	100.00%	2060 / 4860	42.39%	104 / 1620	6.42%
English	1620 / 1620	100.00%	1976 / 4860	40.66%	94 / 1620	5.80%
合计	3240 / 3,240	100.00%	4036 / 9720	41.52%	198 / 3240	6.11%

****计分规则：********仅将可解析的 JSON 中、能唯一对应输入样本、恰有 3 个不同且属于 632 项词表的概念 ID 的输出计入分母。概念 ID 或样本 ID 仅允许确定性的前导零位数归一；原始值保留。每个有效输出有 3 个标准标签，Hits@3 为有效输出的命中标签数 / （有效输出数 × 3）；三标签完全匹配按集合比较。缺失、重复、无效或无法解析的输出不计入分子与分母。

分来源结果

来源	中文有效输出	中文 Hits@3	中文完全匹配	English 有效输出	English Hits@3	English 完全匹配
HAIV	550 / 550	667 / 1650 (40.42%)	33 / 550	550 / 550	651 / 1650 (39.45%)	31 / 550
HL	500 / 500	642 / 1500 (42.80%)	32 / 500	500 / 500	609 / 1500 (40.60%)	21 / 500
IRFL	420 / 420	548 / 1260 (43.49%)	29 / 420	420 / 420	522 / 1260 (41.43%)	32 / 420
MM	150 / 150	203 / 450 (45.11%)	10 / 150	150 / 150	194 / 450 (43.11%)	10 / 150

排除情况与前导零

中文排除 0 个输出： {} 。

English 排除 0 个输出： {} 。

有效输出中，概念 ID 的前导零归一：中文 0 个、English 0 个；样本 ID 的前导零归一：中文 0 个、English 0 个。仅归一格式上属于 PHC- 加数字、归一后确属词表的 ID（如 PHC-1 → PHC-001 、 PHC-0504 → PHC-504 ）。

批次原始结构校验： {'ok': 324} ；结束原因： {'stop': 324} 。

中英文逐图比较

在两种语言均有有效输出的 1620 张图中，中文命中更多 345 张，English 命中更多 262 张，命中相同 1013 张。

测试方法与隔离

- 1,620 张图片按文件名排序，每 10 张为一批；每批中英文独立请求，共 324 次请求。原始单图 prompt 仅改为十图独立判断与合并的 results JSON 输出。
- 请求仅含该语言的 prompt、10 个样本 ID、对应图片和完整 632 项候选词表。运行脚本不读取标准答案 CSV；原始回答保存后由独立评分脚本读取标准答案。此前回答、标准标签和评分结果均未发给模型。

- 3 张 WebP 图片在发送前转为 PNG，原始文件不改动。保存原始最终回答、输入哈希和用量；不保存 API 密钥、图片 base64 或思考过程内容。
- 正式请求设置 `max_tokens=65536` 。开始前的 2 次 `max_tokens=16384` 试运行耗额度且未产生最终回答，原始元数据保存在 `pilot_16384/` ，不属于正式 324 次请求，也不进入准确率或下方用量。
- JSON 语法错误、额外顶层字段、无效样本/概念 ID、重复 ID、非正常结束等均按上述规则排除。逐例 CSV 的 `included_in_accuracy` 与 `exclusion_reason` 可逐条审计。

Token 用量

Prompt	输入 tokens	输出 tokens (含思考)	其中思考 tokens	合计 tokens	返回思考内容的响应数
中文	3,371,310	2,882,579	2,825,557	6,253,889	162 / 162
English	3,372,606	3,131,147	3,074,125	6,503,753	162 / 162

用量来自 API 响应，不含没有返回用量的重试。思考内容本身没有保存。

- [逐例结果 CSV](#)：标准 ID、原始预测、归一后的预测、计分纳入标记及排除原因。
- `raw_high/batch_*.json`：原始最终回答、模型名、输入哈希、用量、结束原因与思考内容长度。
- 标准答案 SHA-256： `6d1f361cd2a813f3fd6e86f2383e82511cd0190dc98fef14c44a12c82038eb3f` ；概念表 SHA-256： `eccefe67f2a213cf5d8dd2c8ac0fe8988925db141af5ddff2720ecc73d06a32b` 。

解释边界

本准确率描述有效输出与现有封闭词表标准答案的 ID 一致程度。排除异常输出会改变分母，因此应同时查看覆盖率；十图批量协议也可能影响模型表现。

API 参考：[DeepSeek 思考模式](#)、[视觉接口](#)。