

DeepSeek-V4.1-Flash

高思考强度检测报告

1620 张图片分别采用中文与英文 prompt 检测，共 3240 个评测项。标签匹配率为 45.77% (4449/9720) ，三标签完全匹配率为 8.18% (265/3240) 。

项目	设置
模型 / 思考强度	deepseek-flash / high
图像 / 评测项	1620 张 / 3240 项
语言 / 批次	中文与英文分别调用 / 10 图一批
报告生成	2026-10-05 16:55 北京时间；离线评分

总体结果

语言	命中数 / 标签位	标签匹配率	完全匹配数 / 项	完全匹配率
中文	2279/4860	46.89%	144/1620	8.89%
英文	2170/4860	44.65%	121/1620	7.47%
中英合计	4449/9720	45.77%	265/3240	8.18%

命中标签数分布

每项命中标签数	中文项数	英文项数	合计项数
0	237	289	526
1	631	613	1244
2	608	597	1205
3	144	121	265

来源分层与评分方法

来源	语言	评测项	标签匹配率	完全匹配率	首选命中率
HAIV	中文	550	42.18%	6.73%	60.36%
HAIV	英文	550	41.52%	6.36%	58.91%
HAIV	中英合计	1100	41.85%	6.55%	59.64%
HL	中文	500	47.87%	9.00%	66.00%
HL	英文	500	45.20%	6.60%	64.60%
HL	中英合计	1000	46.53%	7.80%	65.30%
IRFL	中文	420	49.21%	9.52%	64.76%
IRFL	英文	420	45.24%	8.10%	62.38%
IRFL	中英合计	840	47.22%	8.81%	63.57%
MM	中文	150	54.44%	14.67%	76.00%
MM	英文	150	52.67%	12.67%	67.33%
MM	中英合计	300	53.56%	13.67%	71.67%

评分口径

标签匹配率 = 预测三标签集合与答案三标签集合的交集大小之和 ÷ (有效评测项数 × 3)。仅将三个概念有效且互不重复的输出计入分母，异常输出不计入。本次中文和英文各有 4860 个有效标签位，合计 9720。

三标签完全匹配率 = 预测与答案的三个标签无序集合完全相同的有效评测项数 ÷ 有效评测项数。首选命中率检查模型输出的第一个标签是否属于答案集合；不把 CSV 标签顺序当作排名。

仅按确定性规则归一编号的前导零，如 PHC-1 归一为 PHC-001；原始与计分 ID 均可追溯。本次涉及前导零归一的评测项为 0。

各来源图像数：HAIV 550、HL 500、IRFL 420、MM 150。两种语言均覆盖全部图像；中英合计的评测项数为图像数的两倍。

检测过程与输出质量

本报告使用已保存的高思考强度模型响应进行离线计分。每张图片采用中文和英文 prompt 各检测一次；报告生成新增模型调用为 0。

每次请求包含 10 张图片、对应样本 ID 和完整 632 概念词表，共 162 个图像批次、324 个成功的语言批次。3 张 WebP 图片在发送前转为 PNG，原始文件保持不变。

固定模型 deepseek-flash、thinking.type=enabled、reasoning_effort=high、max_tokens=65536、stream=false。全部成功响应的返回模型名与请求设置均已核验。

检查项	结果
成功批次 / 最终缺失批次	324 / 0
最终有效输出	3240/3240
返回模型及 high 请求参数核验	324/324 通过
原始输出严格格式合规	3240/3240
异常输出 / 有效覆盖率	0 / 100.00%
前导零归一涉及评测项	0
返回思考内容的响应	324/324
图片与原始输入一致	1620/1620；文件名与内容哈希一致

模型身份与思考强度由响应返回名、请求元数据和思考 token 用量联合核验。异常输出排除规则在计分前固定，原始回答保持可追溯。

检测用量

用量项目	Token
输入	6,743,916
输出	6,013,726
输出中推理	5,899,682
输入中缓存	5,164,544
输入 + 输出合计	12,757,642

模型检测时间：2026-09-30 01:59:23 至 2026-09-30 03:03:28 北京时间。用量汇总已保存的 324 个正式成功响应，本次离线评分新增模型 Token 为 0。推理属于输出，缓存属于输入，不重复计入总量；试运行及未保存响应的尝试不在此用量内。

答案隔离与结果核验

模型请求只包含对应语言的 prompt、候选概念词表、样本 ID 与图片。答案 CSV、场景解释、其他语言回答和既有评分结果未进入请求，也未提供外部工具或历史会话。

答案仅由本地评分过程读取，共 1620 行，每行三个不同有效概念，覆盖 440 个概念。已逐张验证图片内容与原始输入哈希一致，并从批次响应和逐例预测两条路径独立核算，统计结果相同。

报告生成未修改答案 CSV 和原始模型回答，未向模型渠道发送答案。PDF 不包含 API Key，也不列出逐图答案；配套逐例 CSV 保留计分结果及纳入标记。

本报告统计预测与所提供答案的精确标签匹配，未开展全量标签语义仲裁。图像可能存在多种哲学解释，标签匹配分数不等同于全部哲学理解能力。

结果核验

逐批核对返回模型、high 请求参数、prompt 和词表哈希；核对全部 1620 张图片内容；分别从原始响应与逐例预测核算命中数、完全匹配和首选命中，逐项一致；生成前后答案与原始记录的内容哈希保持不变。