

GLM-5.3-Flash 检测报告

1620 张图片分别采用中文与英文 prompt 检测，共 3240 个评测项。按照标准答案计算，标签匹配率为 43.41%（4219/9720），三标签完全匹配率为 6.08%（197/3240）。

项目	设置
模型／执行方式	glm-5.3-flash／ZCode 子任务（未设置自定义采样参数）
图像／评测项	1620 张／3240 项
语言／批次	中文与英文分别执行／10 图一批，批内逐图独立分析
报告生成	2026-10-05；离线复评分

总体结果

语言	命中数／标签位	标签匹配率	完全匹配数／项	完全匹配率
中文	2116/4860	43.54%	107/1620	6.60%
英文	2103/4860	43.27%	90/1620	5.56%
中英合计	4219/9720	43.41%	197/3240	6.08%

每项命中标签数	中文项数	英文项数	合计项数
0	275	268	543
1	681	691	1372
2	557	571	1128
3	107	90	197

来源分层

来源	语言	评测项	标签匹配率	完全匹配率	首选命中率
HAIV	中文	550	42.06%	6.55%	63.45%

来源	语言	评测项	标签匹配率	完全匹配率	首选命中率
HAIV	英文	550	42.06%	5.64%	62.00%
HAIV	中英合计	1100	42.06%	6.09%	62.73%
HL	中文	500	42.80%	5.40%	63.00%
HL	英文	500	42.80%	3.40%	62.20%
HL	中英合计	1000	42.80%	4.40%	62.60%
IRFL	中文	420	45.24%	8.33%	61.67%
IRFL	英文	420	43.41%	7.14%	62.62%
IRFL	中英合计	840	44.33%	7.74%	62.14%
MM	中文	150	46.67%	6.00%	66.00%
MM	英文	150	48.89%	8.00%	70.00%
MM	中英合计	300	47.78%	7.00%	68.00%

检测与评分方法

本报告直接使用已完成的模型响应，按照答案 CSV 离线重新计分；报告生成没有重新调用模型，没有改变预测标签或选择新的回答。

每张图片采用中文和英文 prompt 各检测一次，两语言由不同子任务独立执行，不共享对话历史或彼此的输出。每个批次包含 10 张原图、对应样本 ID 和完整 632 概念词表，批内逐图读取、独立判断，共 162 个图像批次、324 个语言批次。中文与英文指令分别取自提供的两份原始评测 prompt 文件，仅将单图输入、单 JSON 输出适配为十图批处理模式。

标签匹配率＝所有预测三标签集合与答案三标签集合的交集大小之和 ÷（评测项数 × 3）。中文和英文各有 4860 个标签位，合计 9720；中英合计将两个语言任务等权汇总。

三标签完全匹配率＝预测与答案的三个标签无序集合完全相同的评测项数 ÷ 评测项数。首选命中率检查模型输出的第一个标签是否属于答案集合；不把 CSV 标签顺序当作排名。

全部预测 ID 均为词表原样三位数 ID；本轮没有需要前导零归一或任何格式修正的评测项，未替换同义词，未改写预测答案。原始批次输出与逐例预测均可追溯。

输出质量

检查项	结果
子任务调度	344 次（324 个语言批次 + 20 次恢复性重跑/拆分）
最终有效输出	3240/3240
首次尝试即得合规批次	314/324
最终原始输出严格格式合规	3240/3240
前导零归一涉及评测项	0
图片与清单一致	1620/1620；样本 ID 与文件名一一对应

批次恢复说明：324 个语言批次中，10 批首次尝试未产出合规结果，全部恢复为有效输出——3 批平台侧失败无输出（1 次调度取消、2 次账户限流，重跑恢复）、5 批批次清单错位（纠错重跑恢复，其中 2 次错位运行的输出经核验后直接用作对应批次的合规结果，未重复调用）、2 批触发平台内容审查误判（拆分为小批次合并恢复）；其中英文样例 PHL1620_IRFL_0326 在子任务通道反复被审查拦截，改由主会话（同模型 glm-5.3-flash）直接读图作答并通过全部校验。每个批次落盘时均经校验脚本强制检查样本 ID 对应、恰好三个互不相同且属于 632 候选表的原样 ID。

答案隔离与解释边界

模型推理请求只包含评测 prompt、候选概念词表、样本 ID 与图片；答案 CSV、评分结果及其他语言回答未进入模型请求，也未提供外部工具或历史会话。

答案仅由本地评分过程读取，共包含 1620 行、每行三个不同有效概念，覆盖 440 个概念；4,860 个概念名称全部经 632 概念词表唯一映射为 ID，无同名多 ID 冲突。评分从逐例预测重新核算，命中总数与批次汇总一致。

报告生成未修改答案 CSV。报告不包含 API Key，也不列出逐图答案。

本报告统计预测与答案的精确标签匹配，未开展全量标签语义仲裁。图像可能存在多种哲学解释，标签匹配分数不等同于全部哲学理解能力。

检测用量

用量项目	数值
子任务调度	344 次
检测时段	2026-09-30（约 10 小时完成 324 个语言批次）
按请求计费的输入/输出 token	未按请求记录

执行框架未按请求记录计费 token 用量；子任务遥测的累计上下文 token（含每批重复加载的词表与图片上下文）与 API 计费口径不可比，故不列入。本次离线报告生成新增模型 token 为 0。

结果核验

逐批校验样本 ID 与图片文件名一一对应、恰好三个互不相同且属于词表的原样 ID；分别从批次输出与逐例预测重新评分，命中总数和完全匹配数一致；报告生成前后答案文件内容保持不变（SHA-256 90f802da0e4f51a6f5608673517d4677e4662d6bcd57ce11679913f06267b16b ）。

可复现文件

- 逐例结果 CSV： PhiloVista-1620_GLM-5.3-Flash_逐例结果.csv （3240 行，含标准 ID、预测 ID、命中数、完全匹配）
- 模型预测： PhiloVista-1620_results_zh.jsonl 、 PhiloVista-1620_results_en.jsonl （各 1620 行）
- 批次原始输出： results/zh/batch_001-162.jsonl 、 results/en/batch_001-162.jsonl
- 评分脚本： scripts/score.js （答案 CSV 副本位于 answers/PhiloVista-1620_labels.csv ）