

PhiloVista-1620：GLM-5.3-Flash 全量中英文评测报告（最终综合答案版）

生成时间：2026-10-04

执行方式：ZCode 子 agent 批量评测（每批 10 张图、批内逐图独立分析）

模型：GLM-5.3-Flash（会话与全部子 agent 统一使用该模型）

规模：1,620 张图片 × 中文、英文各评测一次 = 3,240 个样本语言组合；共 162 批 × 2 种语言，全部批次均得到有效回答，无图片缺失。

本报告为最新版：按"最终综合"答案文件（PhiloVista-1620_labels_最终综合.csv，SHA-256 6d1f361cd2a813f3fd6e86f2383e82511cd0190dc98fef14c44a12c82038eb3f）重新评分，取代此前基于原版答案（SHA-256 4cc427289efc8336b9a39c94863aeee7c610ad8a6162c139888d96a1970718ff）的报告。模型预测文件与此前完全相同，未重跑模型；仅标准答案更换。

准确率

Prompt	命中标签 / 总标签	Hits@3 准确率	三标签完全匹配图片	完全匹配率
中文	1969 / 4860	40.51%	88 / 1620	5.43%
English	1962 / 4860	40.37%	75 / 1620	4.63%
合计	3931 / 9,720	40.44%	163 / 3,240	5.03%

主准确率口径：全部 1,620 张图片纳入分母。每张图的 3 个预测概念 ID 与 3 个标准概念 ID 做无序精确匹配，汇总 Hits@3 = 命中标签数 / (全部图片数 × 3)。完全匹配率 要求 3 个 ID 集合全部一致。标准答案的概念名称列按 philosophical_image_label_system_formal_632.md 的名称-ID 唯一映射转为 ID 后评分；1,620 × 3 = 4,860 个标准概念名全部成功解析，词表内无同名多 ID 冲突。标准标签的列顺序不作为强弱排名，不计算位置准确率。全部预测 ID 均为词表原样三位数 ID，评分未做任何格式归一。

与原版答案的对比（预测不变）：最终综合版相对原版共修改 1,570 / 1,620 张图片的标准标签（4,860 个标签位中变更 2,904 个，占 59.8%）。按新答案计，中文 Hits@3 由 33.13% 升至 40.51%（+7.38 个百分点），English 由 33.05% 升至 40.37%（+7.32 个百分点）；三标签完全匹配由 54 / 3,240 升至 163 / 3,240。准确率变化完全来自标准答案修订，不代表模型输出变化。

分来源结果

来源	有回答图 (中/英)	中文命中 / 标签	中文 Hits@3	中文完全匹配	English 命中 / 标签	English Hits@3	English 完全匹配
HAIV	550 / 550	691 / 1650	41.88%	40 / 550	699 / 1650	42.36%	33 / 550
HL	500 / 500	576 / 1500	38.40%	17 / 500	571 / 1500	38.07%	12 / 500
IRFL	420 / 420	519 / 1260	41.19%	26 / 420	503 / 1260	39.92%	24 / 420
MM	150 / 150	183 / 450	40.67%	5 / 150	189 / 450	42.00%	6 / 150

中英文逐图比较

在 1,620 张图中，中文命中更多：352 张；English 命中更多：344 张；命中数相同：924 张。中英答案 3/3 完全一致的图片 229 张（14.1%），平均每样本概念重叠 1.69/3（这两项为模型间一致性指标，与标准答案版本无关，数值与此前报告一致）。此为同一图片的配对描述统计，未作显著性检验或因果归因。

输出格式与词表合规

中文 1,620 / 1,620、English 1,620 / 1,620 张图片的输出格式和词表合规（合规率 100%）：样本 ID 与图片文件名一一对应、恰好三个不同且属于 632 候选表的原样 ID。该合规由流水线内校验脚本（scripts/check.js）在每批落盘时强制执行，越界或格式错误的批次会被自动发现并重跑，因此进入评分的数据全部合规。

评测过程中 2 个英文批次（en 127、en 138）曾触发平台内容安全审查误判，按更小子批次拆分后全部恢复；其中 PHL1620_IRFL_0326（雨中人海俯拍图）在子 agent 通道反复被拦截，改由主会话（同模型 GLM-5.3-Flash）直接读图作答，答案同样通过全部校验。最终中文、英文均为 1,620 / 1,620 全覆盖，无无回答样例。

测试方法与防泄露

- 按图片文件名排序，连续 10 张组成一批；每批分别用中文和 English 指令各执行一次，两个语言的评测由不同子 agent 独立进行，不共享对话历史或彼此的输出。批内每张图逐一读取、独立判断，互不影响；每批上下文仅包含样本 ID、对应原图和完整 632 概念候选表。
- 两份评测 prompt 分别取自 主评测_prompt_中文.txt 与 主评测_prompt_English.txt 原文；仅将"单图输入、单 JSON 输出"适配为十图批处理模式，原有的判断规则与选 3 个候选 ID 的要求保持原样。
- 评测 agent 不读取任何标准答案文件；全部预测落盘后，才由独立的评分脚本（scripts/score.js）离线读入标准答案计分。标准答案、评分结果均未进入任何模型请求。概念表中的候选名称进入请求，因为模型必须从中选择 ID。
- 图片内文字和概念表文本被明确作为数据而非指令（prompt 规则 4 原样生效）。批次中间产物与最终合并文件均落盘可复查。

可复现文件

- 中文最终结果、English 最终结果：各 1,620 行，每行
{"sample_id":"...","concept_ids":[...] }，按视觉依据强到弱排序。
- 逐例结果 CSV（最终综合答案）：每张图、每种语言的标准 ID、预测 ID、命中数与完全匹配标记，共 3,240 行，全部计入全量准确率。
- answers/PhiloVista-1620_labels_最终综合.csv（本次评分用标准答案副本）、answers/PhiloVista-1620_labels_原版.csv（原版答案副本，用于差异统计）。
- results/zh/batch_001-162.jsonl、results/en/batch_001-162.jsonl：各批次原始输出。
- 校验与合并脚本、中英一致性对比、评分脚本（当前默认按最终综合答案评分，更换 ANSWER_FILE 常量可复评其他版本）。
- 标准答案 SHA-256：最终综合版
6d1f361cd2a813f3fd6e86f2383e82511cd0190dc98fef14c44a12c82038eb3f；原版
4cc427289efc8336b9a39c94863aeec7c610ad8a6162c139888d96a1970718ff；概念表
eccefe67f2a213cf5d8dd2c8ac0fe8988925db141af5ddff2720ecc73d06a32b。

解释边界

准确率反映与现有封闭词表标准答案的 ID 精确一致程度。哲学图像可有多种合理解释，失配不必然表示预测完全不合理；本报告没有人工复核标准标签。标准答案由原版修订为最终综合版后，同一批预测的准确率上升约 7.4 个百分点，说明两版答案的判定口径差异对得分影响显著，跨答案版本的准确率不宜直接比较。本次协议为"十图一批会话内逐图独立分析"，与其他调用协议（如十图合并单次 API 请求中输出）的表现可能不同，跨协议的模型间准确率比较需谨慎。