

GPT-6 Astra

高思考强度检测报告

1620 张图片分别采用中文与英文 prompt 检测，共 3240 个评测项。按照最新答案计算，标签匹配率为 68.43%（6651/9720），三标签完全匹配率为 28.49%（923/3240）。

项目	设置
模型 / 思考强度	gpt-6-astra / high
图像 / 评测项	1620 张 / 3240 项
语言 / 批次	中文与英文分别调用 / 10 图一批
报告生成	2026-10-05 16:17 北京时间；离线复评分

总体结果

语言	命中数 / 标签位	标签匹配率	完全匹配数 / 项	完全匹配率
中文	3369/4860	69.32%	481/1620	29.69%
英文	3282/4860	67.53%	442/1620	27.28%
中英合计	6651/9720	68.43%	923/3240	28.49%

命中标签数分布

每项命中标签数	中文项数	英文项数	合计项数
0	38	48	86
1	276	304	580
2	825	826	1651
3	481	442	923

来源分层与评分方法

来源	语言	评测项	标签匹配率	完全匹配率	首选命中率
HAIV	中文	550	61.27%	20.36%	78.00%
HAIV	英文	550	59.21%	16.18%	76.73%
HAIV	中英合计	1100	60.24%	18.27%	77.36%
HL	中文	500	73.47%	32.80%	90.80%
HL	英文	500	71.80%	32.00%	84.00%
HL	中英合计	1000	72.63%	32.40%	87.40%
IRFL	中文	420	73.73%	37.14%	86.90%
IRFL	英文	420	71.51%	34.05%	89.52%
IRFL	中英合计	840	72.62%	35.60%	88.21%
MM	中文	150	72.67%	32.67%	92.67%
MM	英文	150	72.67%	33.33%	89.33%
MM	中英合计	300	72.67%	33.00%	91.00%

评分口径

标签匹配率 = 所有预测三标签集合与答案三标签集合的交集大小之和 ÷ (评测项数 × 3)。中文和英文各有 4860 个标签位，合计 9720；中英合计将两个语言任务等权汇总。

三标签完全匹配率 = 预测与答案的三个标签无序集合完全相同的评测项数 ÷ 评测项数。首选命中率检查模型输出的第一个标签是否属于答案集合；不把 CSV 标签顺序当作排名。

只允许编号补齐前导零，例如 PHC-1 归一为 PHC-001；不替换同义词，不改写预测答案。原始与计分 ID 均可追溯，本轮没有需要前导零归一的评测项。

各来源图像数：HAIV 550、HL 500、IRFL 420、MM 150。中文、英文均覆盖全部图像；“中英合计”的评测项数为该来源图像数的两倍。

检测过程与输出质量

本报告直接使用已完成的高思考强度模型响应，按照最新 CSV 离线重新计分；报告生成没有重新调用模型，没有改变预测标签或选择新的回答。

每张图片采用中文和英文 prompt 各检测一次。每次请求包含 10 张原图、对应样本 ID 和完整 632 概念词表，共 162 个图像批次、324 次成功的语言批次。

固定模型 gpt-6-astra、reasoning.effort=high、image detail=auto、store=false、stream=true；成功响应的返回模型与思考强度均已核验。返回模型身份来自指定第三方渠道的信息。

检查项	结果
成功批次 / 失败批次	324 / 0
最终有效输出	3240/3240
成功响应返回模型及 high 参数	324/324 通过
首次尝试严格格式合规	3160/3240
最终原始输出严格格式合规	3240/3240
前导零归一涉及评测项	0
记录的 API 尝试 / 额外重试	332 / 8
图片与推理清单一致	1620/1620；文件名与行顺序一致

首次尝试格式合规统计将首次传输失败计为没有获得合规输出；因此它衡量首次调用流程成功率，不单独衡量已返回内容的格式错误率。

检测用量

用量项目	Token
输入	7,727,202
输出	1,413,876
输出中推理	1,305,832
输入中缓存	4,008,064
输入 + 输出合计	9,141,078

模型检测时间：2026-10-05 01:19:58 至 03:14:53 北京时间。用量来自这次已记录的高强度检测及重试响应；本次离线报告生成新增模型 Token 为 0。推理 Token 属于输出，缓存 Token 属于输入，不重复计入总量。未返回用量的失败尝试可能未计入，不换算渠道费用。

答案隔离与结果核验

模型推理请求只包含冻结的 prompt、候选概念词表、样本 ID 与图片；答案 CSV、场景解释、训练文件及其他语言回答未进入模型请求，也未提供外部工具或历史会话。

答案仅由本地评分过程读取，共包含 1620 行、每行三个不同有效概念，覆盖 440 个概念。已逐张验证图片内容与检测时保存的清单一致，并从保存的批次结果和逐例预测两条路径核算，统计结果相同。

报告生成未修改答案 CSV，未向模型渠道发送答案。报告不包含 API Key，也不列出逐图答案。

本报告统计预测与答案的精确标签匹配，未开展全量标签语义仲裁。图像可能存在多种哲学解释，标签匹配分数不等同于全部哲学理解能力。

结果核验

逐批确认返回模型和 high 思考参数；核对 1620 张图片内容；分别从批次输出与逐例预测重新评分，命中总数和完全匹配数一致；报告生成前后答案文件内容保持不变。