

Qwen3.7-Flash

非思考模式检测报告

1620 张图片分别采用中文与英文 prompt 检测，共 3240 个评测项。标签匹配率为 28.28% (2749/9720) ，三标签完全匹配率为 0.90% (29/3240) 。

项目	设置
模型 / 思考模式	qwen3.7-flash / 非思考模式
图像 / 评测项	1620 张 / 3240 项
语言 / 批次	中文与英文分别调用 / 10 图一批
报告生成	2026-10-05 北京时间；离线评分

总体结果

语言	命中数 / 标签位	标签匹配率	完全匹配数 / 项	完全匹配率
中文	1363/4860	28.05%	15/1620	0.93%
英文	1386/4860	28.52%	14/1620	0.86%
中英合计	2749/9720	28.28%	29/3240	0.90%

命中标签数分布

每项命中标签数	中文项数	英文项数	合计项数
0	575	559	1134
1	742	750	1492
2	288	297	585
3	15	14	29

来源分层与评分方法

来源	语言	评测项	标签匹配率	完全匹配率	首选命中率
HAIV	中文	550	25.27%	0.73%	40.55%
HAIV	英文	550	26.97%	0.55%	43.27%
HAIV	中英合计	1100	26.12%	0.64%	41.91%
HL	中文	500	29.67%	1.00%	50.40%
HL	英文	500	29.87%	0.80%	49.40%
HL	中英合计	1000	29.77%	0.90%	49.90%
IRFL	中文	420	30.95%	1.19%	49.05%
IRFL	英文	420	31.19%	1.43%	46.43%
IRFL	中英合计	840	31.07%	1.31%	47.74%
MM	中文	150	24.67%	0.67%	36.67%
MM	英文	150	22.22%	0.67%	38.00%
MM	中英合计	300	23.44%	0.67%	37.33%

评分口径

标签匹配率 = 预测与答案三标签无序集合的交集大小之和 ÷ (评测项数 × 3)。中文和英文各有 4860 个标签位，合计 9720；两种语言等权汇总。服务端拒绝且无回答项仍纳入分母，计 0 命中。

三标签完全匹配率 = 预测与答案三个标签无序集合完全相同的项数 ÷ 评测项数。首选命中率检查模型输出的第一个标签是否属于答案集合；不把 CSV 标签顺序当作排名，无回答项计为未命中。

仅按确定规则归一编号的前导零宽度，例如 PHC-10→PHC-010、PHC-0269→PHC-269，且归一后须属于词表；不替换同义词或改写预测。归一涉及中文 140 项、英文 77 项，共 217 项 (239 个 ID)；原始与计分 ID 均保留。

各来源图像数：HAIV 550、HL 500、IRFL 420、MM 150。两种语言均将全部图像纳入分母；中英合计的项数为图像数的两倍。

检测过程与输出质量

本报告使用已保存的模型响应进行离线评分；报告生成没有重新调用模型，也没有改变原始预测标签或选择新的回答。

每张图片采用中文和英文 prompt 各检测一次；主请求为 10 张原图、样本 ID 与完整 632 概念词表，共 162 个图像批次、324 个语言请求。其中 8 个主请求因服务端图片审查被拒绝，按原顺序拆分子批次恢复；另补测 1 个英文漏答项。

模型 qwen3.7-flash，temperature=0、enable_thinking=false、max_tokens=2048、stream=false。全部成功响应的返回模型名均已核验。

检查项	结果
主请求成功 / 审查拒绝	316 / 8
恢复成功响应	31
最终获得模型预测	3230/3240
归一后有效三标签输出	3230/3240
成功响应返回模型	347/347 通过
原始输出严格格式合规	3013/3240
前导零归一涉及评测项	217
当前图片与推理记录内容一致	1620/1620；逐图哈希核验

原始格式合规要求恰有三个不同的原样词表 ID。服务端拒绝、模型漏答和前导零异常均保留记录；语义正确性与格式合规分别统计。

检测用量

用量项目	Token
输入	7,913,970
输出	221,502
输入中图像	2,364,216
输入中缓存	1,325,184
输入 + 输出合计	8,135,472

原始模型响应保存时间：2026-09-30 00:57:44 至 2026-09-30 01:18:13 北京时间。用量来自 347 次成功主请求及恢复响应；本次报告新增模型 Token 为 0。图像与缓存 Token 属于输入，不重复计入总量。未返回用量的失败尝试未计入；请求尝试日志不完整，因此不报告精确尝试总数或渠道费用。

答案隔离与结果核验

模型推理请求只包含对应语言 prompt、候选概念词表、样本 ID 与图片；答案 CSV、其他语言回答及既有评分结果未进入请求，也未提供外部工具或历史会话。

答案仅由本地评分过程读取，共 1620 行，每行三个不同有效概念，覆盖 440 个概念。已逐张验证当前图片内容与推理记录一致，并从原始批次响应和逐例 CSV 两条路径独立核算，逐项结果相同。

报告生成未修改答案 CSV 或原始模型记录，未向模型渠道发送答案。PDF 不包含 API Key，也不列出逐图答案；详细计分结果保存于配套 CSV。

中文与英文各有 5 张图片经单图提交仍被服务端审查拒绝，故最终各取得 1615 个预测。无回答项计为 0 命中；仅统计有回答项时，中文与英文标签匹配率分别为 28.13%、28.61%。

本报告统计预测与答案的精确标签匹配，未开展全量标签语义仲裁。图像可能存在多种哲学解释，匹配分数不等同于全部哲学理解能力。

配套审计记录表明，评测标签经过事后模型输出校准，不能视为独立于模型输出的人工标准；本报告的指标用于衡量与这些标签的匹配程度。

结果核验

核对全部 1620 张图片的内容哈希、prompt 与词表哈希；逐次确认 347 个成功响应的返回模型；独立重算 3240 个评测项的命中数和完全匹配状态，与逐例 CSV 一致；生成前后答案和原始记录的文件内容均保持不变。