

PhiloVista-1620: Qwen3.7-Flash 新标准答案评测报告

重新评分日期：2026-10-04 (Asia/Shanghai)

API 请求时间：2026-09-29T16:57:44.350077+00:00 至 2026-09-29T17:18:13.061986+00:00

模型：qwen3.7-flash (所有成功响应返回的模型名均一致)

规模：1,620 张图片 × 中文、英文各尝试一次 = 3,240 个样本语言组合；原定每次请求 10 张图片，共 162 批 × 2 种语言。遭服务端图片审查拒绝的整批请求改用更小子批次恢复。

新标准答案与重评分说明

重新评分日期：2026-10-04 (Asia/Shanghai)。本次使用用户指定的新标准答案，对原先保存的 3,240 个样本语言记录离线重新评分；模型请求仍为原始测试时间，新增 API 调用为 0，新增推理 tokens 为 0。

标准答案来源：[D:/Project/PhiloVista-1800-A-Multi-source-Benchmark/PhiloVista-1620_labels.csv](#)。文件包含 1,620 个唯一文件名，与原评测图片一一对应；全部标签名称均精确映射到原 632 概念词表，每图恰有三个不同标签。

与上一版标准答案比较，标签集合改变 1570 / 1,620 张；来源分布为 HAIV 525、HL 487、IRFL 411、MM 147 张。此处比较无序标签集合，仅改变标签顺序不计入集合变化。

Prompt	旧命中数	新命中数	旧全量 Hits@3	新全量 Hits@3	变化 (百分点)	旧完全匹配图	新完全匹配图
中文	1046	1281	21.52%	26.36%	+4.84	2	11
English	1056	1283	21.73%	26.40%	+4.67	5	10

上述变化来自标准答案更新；模型输出、前导零归一规则和全量分母均沿用原评测协议，因此不能据此判断模型能力发生变化。

准确率

Prompt	命中标签 / 总标签	Hits@3 准确率	三标签完全匹配图片	完全匹配率
中文	1281 / 4860	26.36%	11 / 1620	0.68%
English	1283 / 4860	26.40%	10 / 1620	0.62%
合计	2564 / 9,720	26.38%	21 / 3,240	0.65%

主准确率口径：全部图片纳入分母；服务端拒绝且无回答的图片计 0 命中。每张图的 3 个预测概念 ID 与 3 个标准概念 ID 做无序精确匹配，汇总 $Hits@3 = \text{命中标签数} / (\text{全部图片数} \times 3)$ 。对仅前导零位数错误且归一后确属词表的 ID（如 PHC-10 → PHC-010、PHC-0504 → PHC-504）统一做确定性格式归一，再评分；原始预测另列保留，其他越界 ID 不修正。完全匹配率要求 3 个 ID 集合全部一致。标准标签的列顺序不作为强弱排名，不计算位置准确率。

只有在有提取到预测的图片上计算，中文为 1281 / 4845（26.44%），English 为 1283 / 4845（26.48%）。此为补充口径，非上表的全量准确率。

实际返回模型答案：中文 1615 / 1,620 张，English 1615 / 1,620 张；其余样例的服务端状态在后文单列。

分来源结果（仅统计有模型回答的图片）

来源	有回答图（中/英）	中文命中 / 标签	中文 Hits@3	中文完全匹配	English 命中 / 标签	English Hits@3	English 完全匹配
HAIV	550 / 550	405 / 1650	24.55%	3 / 550	423 / 1650	25.64%	1 / 550
HL	500 / 500	408 / 1500	27.20%	2 / 500	401 / 1500	26.73%	3 / 500
IRFL	418 / 418	366 / 1254	29.19%	5 / 418	368 / 1254	29.35%	6 / 418
MM	147 / 147	102 / 441	23.13%	1 / 147	91 / 441	20.63%	0 / 147

中英文逐图比较

在中英文均有模型回答的 1615 张图中，中文命中更多：239 张；English 命中更多：245 张；命中数相同：1131 张。此为同一图片的配对描述统计，未作显著性检验或因果归因。

输出格式与词表合规

中文：1475 / 1615 张有回答图片的原始输出格式和词表合规；English：1538 / 1615 张。合规要求样本 ID 正确、恰好三个不同且属于 632 候选表的原样 ID。

成功响应的原始结构与词表全合规：259 / 347。违规原因计数：{'invalid_concept_id': 87, 'wrong_result_count': 1}。前导零归一数：中文 158 个、English 81 个；未经归一时，已回答样例的命中数和准确率分别为中文 1225 / 4,845（25.28%）、English 1246 / 4,845（25.72%）。归一只发生在离线评分阶段，原始回答未改写，也未回传给模型。

服务端拒绝且单图仍无法得到回答：中文 5 张、English 5 张。对应逐例 CSV 的预测列为空；这些图片已被实际提交测试，但没有模型输出。

单图仍被服务端拒绝的样例

样本 ID	中文	English
PHL1620_IRFL_0049	无回答	无回答
PHL1620_IRFL_0387	无回答	无回答
PHL1620_MM_0135	无回答	无回答
PHL1620_MM_0142	无回答	无回答
PHL1620_MM_0144	无回答	无回答

测试方法与防泄露

- 按图片文件名排序，连续 10 张组成一批；每批分别用中文和 English 指令独立请求一次。两个语言的请求不共享对话历史或彼此的输出。每批仅发送样本 ID、对应原图和完整 632 概念候选表。被服务端 `data_inspection_failed` 拒绝的整批请求按连续子批次拆分，直至可返回或确定单图仍被拒绝；不修改图片、不绕过服务端拒绝。
- 两份原始主评测 prompt 分别从提供的 txt 文件读取，仅将单图输入和单图 JSON 输出格式改成十图批量格式；每张图的原有判断规则保持原样，独立选 3 个候选 ID。实际发送的 prompt 可由 `run_full.py` 的 `batch_instruction` 复现，哈希随请求记录。
- 模型调用脚本不读取 `PhiloVista-1620_labels.csv`。原始响应保存后才由独立的 `score_full.py` 读取标准答案评分。标准答案、此前模型回答和评分结果均未进入模型请求。概念表中的候选名称会进入请求，因为模型必须从中选择 ID。
- 图片内文字和概念表文本被明确作为数据而非指令。脚本不在控制台打印预测内容，也不把 API 密钥写入结果。每批原始响应保存在 `raw/`；单独记录 JSON 结构、样本 ID、词表 ID 和返回模型名检查结果。
- API 设置：OpenAI 兼容 Chat Completions 接口；`temperature=0`、`enable_thinking=false`、`max_tokens=2048`、`stream=false`。未使用强制 JSON 参数；每次独立调用，未做答案修正。模型响应格式或词表错误保留原样；仅前导零宽度错误在离线评分时按固定规则归一。

用量与可复现文件

Prompt	成功响应数	输入 tokens	输出 tokens	合计 tokens
中文	173	3,946,792	110,711	4,057,503
English	174	3,967,178	110,791	4,077,969

上表为原始测试的历史用量；本次更换标准答案重新评分未产生新增 API 调用或推理 tokens。历史统计不含服务端拒绝或早期重试请求的未返回用量。

- 逐例结果 CSV：每张图、每种语言的三个标准 ID、原始与评分用预测 ID、命中数、完全匹配、原始格式标记及 `has_extracted_prediction` 标记。所有 3,240 行均计入全量准确率。
- 原始记录目录：`D:/Project/多模态benchmark/qwen3.7-flash/PhiloVista-1620-rerun/raw`；`batch_*.json` 和 `raw/recovery_batch_*.json`：原始回答、模型名、用量、时间和输入哈希；被拒绝的单图记录只有错误代码及输入哈希。未保存完整请求体或密钥。
- 调用脚本；拒绝批次恢复脚本；评分脚本；本次重评分脚本。
- 标准标签文件 SHA-256：`6d1f361cd2a813f3fd6e86f2383e82511cd0190dc98fef14c44a12c82038eb3f`；概念表 SHA-256：`eccefe67f2a213cf5d8dd2c8ac0fe8988925db141af5ddff2720ecc73d06a32b`。
- 标准答案变更对照 CSV：1,620 张图片的旧新标签及两种语言命中数变化。

解释边界

准确率反映与现有封闭词表标准答案的 ID 精确一致程度。哲学图像可有多种合理解释，失配不必然表示预测完全不合理；本报告没有人工复核标准标签。十图同请求可节省重复发送概念表的输入 tokens，但与逐图独立调用的表现可能不同，因此结果代表本次十图批量协议。

API 参考：Qwen3.7-Flash 模型说明、视觉理解接口说明。